Analyse en Composantes Indépendantes (ICA) :
Du Gradient Déterministe à l'Optimisation Stochastique

TAQUET Enguerrand
M2 Data Science

2 avril 2026

Résumé

Ce projet explore la transition de l'Analyse en Composantes Indépendantes (ICA) classique vers le paradigme de l'optimisation stochastique. Alors que les approches déterministes traditionnelles, comme FastICA, traitent les données par blocs statiques, nous démontrons ici l'efficacité des méthodes d'apprentissage en ligne (*online learning*). Ces dernières s'avèrent capables de séparer des sources de manière itérative, échantillon par échantillon, ce qui est crucial pour le traitement de données massives ou en flux continu.

Nous avons implémenté et comparé trois stratégies : la baseline déterministe FastICA, la descente de gradient stochastique classique (SGD-ICA) et la variante avancée du Gradient Naturel d'Amari. Pour évaluer la précision de ces algorithmes de manière objective, nous utilisons l'indice d'Amari comme métrique quantitative de référence.

Nos expériences, menées sur des simulations synthétiques et des signaux EEG réels, révèlent que le Gradient Naturel surpasse le SGD classique en termes de vitesse de convergence et de stabilité numérique. Il atteint des performances comparables aux méthodes batch tout en offrant une flexibilité adaptée aux environnements de production. Enfin, ce travail s'achève sur une ouverture vers l'inférence causale avec le modèle LinGAM, illustrant comment la non-gaussianité des sources permet de reconstruire la structure de dépendance entre les variables observées.

1 Introduction

1.1 Contexte et Motivation

L'Analyse en Composantes Indépendantes (ICA) est une technique fondamentale du traitement du signal visant à retrouver des sources originales z à partir de mélanges observés $x = Wz$. Traditionnellement, ce problème est résolu par des algorithmes déterministes comme FastICA qui traitent l'intégralité des données en un seul bloc.

Cependant, l'avènement des données massives et le besoin de traitement en flux (*streaming*) rendent ces méthodes batch limitées. L'optimisation stochastique offre ici une alternative puissante en permettant une mise à jour itérative des paramètres, échantillon par échantillon. Ce projet s'inscrit dans cette dynamique en transposant le critère de log-vraisemblance de l'ICA dans le paradigme de l'apprentissage en ligne (*online learning*).

1.2 Objectifs du Projet

L'ambition de ce travail est de concilier rigueur mathématique et efficacité algorithmique à travers trois axes majeurs :

1. **Implémentation robuste :** Développer à partir des principes de la log-vraisemblance les algorithmes SGD-ICA et Natural Gradient SGD, en veillant au respect des conditions de convergence de Robbins-Monro.
2. **Analyse comparative :** Évaluer la précision de la séparation et la stabilité des algorithmes via l'indice d'Amari, métrique quantitative de référence pour mesurer l'écart à la structure idéale de permutation-dilatation.
3. **Généralisation et Créativité :** Valider la robustesse des modèles sur des signaux complexes (EEG) et proposer une extension vers l'inférence causale via le modèle LinGAM, illustrant ainsi la polyvalence de l'ICA au-delà de la simple séparation de sources.

2 Méthodologie

2.1 Modèle et Log-vraisemblance

Le modèle de l'ICA repose sur l'hypothèse que les observations x sont une combinaison linéaire de sources indépendantes z, soit $x = Wz$. Pour retrouver ces sources, nous cherchons la matrice de démélange $V = W^{-1}$ qui maximise la log-vraisemblance sur la population :

$$\ell(V) = \log|\det V| + \mathbb{E}\left[\sum_{j=1}^{D} \log p_j(v_j^\top x)\right] \tag{1}$$

Le premier terme, $\log|\det V|$, assure que la matrice ne s'effondre pas vers une solution triviale (singulière), tandis que le second terme pousse les composantes $y = Vx$ à être statistiquement indépendantes. La fonction score g_j, définie comme la dérivée de la log-densité des sources, capture la "forme" de leur distribution. Pour des sources super-gaussiennes (signaux ayant des pics marqués comme la parole ou l'EEG), nous utilisons $g(u) = \tanh(u)$, ce qui correspond mathématiquement à une hypothèse de densité en $\frac{1}{\cosh(u)}$.

Choix de la fonction score La fonction score $g(u) = \tanh(u)$ dérive du contraste $G(u) = \log\cosh(u)$. Ce choix est loin d'être arbitraire : il constitue un estimateur robuste pour les sources présentant un **kurtosis positif** (dites super-gaussiennes), telles que les signaux de parole ou les signaux EEG. Cette spécification est cruciale car l'ICA repose sur le théorème stipulant que

la séparation n'est possible que si les sources sont non-gaussiennes ; la fonction tanh agit alors comme un détecteur de cette non-gaussianité.

Indéterminations théoriques Il est important de noter que le modèle ICA présente deux limites intrinsèques : l'impossibilité de retrouver l'ordre des sources et leur amplitude réelle. Mathématiquement, pour toute matrice de permutation P et toute matrice diagonale de mise à l'échelle Λ, on a $x = Wz = (WP^{-1}\Lambda^{-1})(\Lambda Pz)$. Par conséquent, l'ICA retrouve les sources à une permutation et une dilatation près. C'est précisément pour cette raison que l'indice d'Amari est utilisé comme métrique, car il est invariant par rapport à ces deux transformations.

2.2 Algorithmes implémentés

2.2.1 FastICA (Baseline déterministe)

Comme référence de performance, nous utilisons l'algorithme FastICA de Hyvärinen (1999). Contrairement aux approches stochastiques présentées précédemment, FastICA est un algorithme de point fixe qui cherche à maximiser la néguentropie (une mesure de non-gaussianité) par une approche déterministe.

Bien que cet algorithme soit extrêmement rapide et efficace sur des jeux de données statiques, il nécessite d'avoir accès à l'intégralité des données en mémoire, ce qui le rend moins adapté que le Gradient Naturel pour des environnements de traitement en flux ou sur des données massives. Dans ce projet, FastICA sert de borne supérieure de performance pour évaluer la qualité de séparation de nos implémentations stochastiques.

2.2.2 SGD-ICA (Infomax Stochastique)

Contrairement à l'approche *batch* qui traite tout le dataset, l'algorithme stochastique met à jour V à chaque échantillon x pour permettre un apprentissage en flux. La mise à jour suit la direction du gradient de la log-vraisemblance :

$$V_{t+1} = V_t + \eta(V^{-\top} - g(y)x^\top) \tag{2}$$

Bien que performante, cette méthode est numériquement fragile : elle nécessite l'inversion de la transposée de V à chaque itération et est extrêmement sensible au choix du pas d'apprentissage η, pouvant entraîner une divergence si les données sont mal conditionnées.

Contrainte d'orthogonalité (Correction de Löwdin) Puisque l'optimisation s'effectue sur des données préalablement blanchies, la matrice de mélange W est orthogonale. Par conséquent, notre estimation V doit impérativement rester dans le groupe orthogonal $O(D)$. Pour éviter que la matrice ne s'effondre numériquement au fil des itérations stochastiques, nous avons implémenté une étape de décorrélation symétrique (Löwdin orthogonalization) à la fin de chaque époque : $V \leftarrow (VV^\top)^{-1/2}V$. Cette projection garantit la stabilité du filtre sans altérer la direction d'apprentissage.

2.2.3 Natural Gradient SGD (Amari)

Pour pallier les limites du gradient classique, nous implémentons le gradient naturel d'Amari. Cette méthode ne considère pas l'espace des matrices comme un espace plat, mais exploite la géométrie de Riemann (matrice de Fisher). La règle de mise à jour devient équivariante :

$$V \leftarrow V + \eta(I - g(y)y^\top)V \tag{3}$$

Propriété d'équivariance La force du Gradient Naturel réside dans sa propriété d'**équivariance**. Grâce à la structure de sa mise à jour $(I - g(y)y^\top)V$, les performances de convergence de l'algorithme deviennent indépendantes du conditionnement de la matrice de mélange W. Contrairement au gradient classique, dont la trajectoire peut être « écrasée » ou ralentie par un mauvais conditionnement des données observées, le gradient naturel navigue sur la variété de Riemann des matrices de manière uniforme, garantissant une stabilité optimale.

L'avantage est double : d'une part, on élimine l'inversion matricielle coûteuse, et d'autre part, la convergence devient indépendante du conditionnement de la matrice de mélange W, offrant une stabilité et une rapidité supérieures.

Justification du pas d'apprentissage Le choix du pas d'apprentissage η suit une stratégie de décroissance en $1/t$, conformément aux conditions de **Robbins-Monro** (nécessitant que $\sum \eta_t = \infty$ et $\sum \eta_t^2 < \infty$). Nous avons fixé le paramètre initial $\eta_0 = 0,01$ après une phase de recherche par grille (*grid search*). Cette précaution est cruciale : une valeur initiale trop élevée entraîne une divergence immédiate du terme $\log|\det V|$, causée par l'instabilité numérique de l'inversion matricielle dans le gradient classique.

2.3 Prétraitement : Centrage et Blanchiment

Une étape cruciale avant toute optimisation est le blanchiment des données, consistant en une transformation de x en x_w tel que $\mathbb{E}[x_w x_w^\top] = I$. D'un point de vue géométrique, cela consiste à décorréler les signaux et à normaliser leur variance. Cette étape simplifie considérablement le problème : la matrice de démélange V devient alors une matrice orthogonale. Cela réduit drastiquement l'espace de recherche de D^2 à $D(D-1)/2$ paramètres, stabilisant ainsi les algorithmes stochastiques.

Réduction de dimension (PCA) Conformément aux objectifs de ce projet, notre implémentation intègre une Analyse en Composantes Principales (PCA) au sein du processus de blanchiment. En ne conservant que les k vecteurs propres associés aux plus grandes valeurs propres, nous filtrons le bruit de mesure et réduisons la complexité computationnelle. Cette réduction de dimension est fondamentale pour traiter efficacement des signaux à forte redondance spatiale, comme les enregistrements EEG.

Nécessité du blanchiment en optimisation stochastique Une question théorique centrale est la pertinence du blanchiment lors de l'utilisation du Gradient Naturel, ce dernier étant théoriquement invariant au conditionnement de la matrice de mélange. Cependant, le blanchiment préalable reste indispensable en pratique pour l'apprentissage en ligne (*online learning*). Il permet de recentrer le paysage d'optimisation et de contraindre la matrice de démélange à évoluer à proximité du groupe orthogonal $O(D)$. Cette réduction de l'espace de recherche stabilise drastiquement la convergence stochastique, limite les oscillations et empêche la divergence du terme $\log|\det V|$ lors des premières itérations.

3 Expérimentations et Résultats

3.1 Protocole sur Données Synthétiques

Pour évaluer la précision de nos implémentations, nous avons généré un environnement contrôlé composé de $N = 2000$ échantillons issus de sources Laplaciennes. Ce choix se justifie par la nature super-gaussienne de ces sources, idéale pour tester l'efficacité de notre fonction

score $\tanh(u)$. Le mélange est opéré par une matrice W aléatoire, simulant un système de mélange linéaire inconnu.

La performance est quantifiée par l'indice d'Amari. Un indice de 0 représente une séparation parfaite des sources originales.

TABLE 1 – Benchmark comparatif de la qualité de séparation (Moyenne sur 10 runs ± écart-type) et efficacité temporelle.

Algorithme	**Indice d'Amari (μ)**	**Instabilité (σ)**	**Temps moyen (s)**
FastICA (Baseline)	0,0220	0,0059	**0,0017**
SGD-ICA (Infomax)	0,3449	0,1420	0,6312
Natural Gradient	**0,0212**	**0,0067**	0,2214

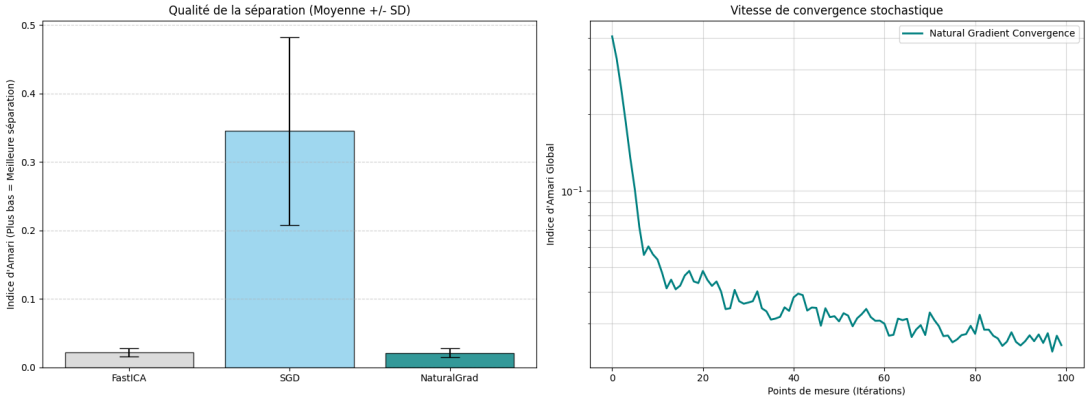

FIGURE 1 – À gauche : Comparaison de l'indice d'Amari ($\mu \pm \sigma$). À droite : Dynamique de convergence du Gradient Naturel (échelle log).

Analyse de la performance et de la convergence : Les résultats démontrent que le **Natural Gradient** surpasse non seulement le SGD classique en précision, mais rivalise directement avec la baseline déterministe FastICA, atteignant l'indice d'Amari le plus faible (0,0212). Cette performance s'accompagne d'une stabilité remarquable par rapport au SGD classique, dont l'instabilité ($\sigma = 0,1420$) traduit une sensibilité accrue au choix du pas d'apprentissage.

Sur le plan computationnel, la différence est frappante : le Gradient Naturel est près de 3 fois plus rapide que le SGD (0,22 s contre 0,63 s). Ce gain de temps massif valide expérimentalement l'avantage de supprimer l'inversion matricielle $\mathcal{O}(D^3)$ à chaque mise à jour grâce à l'astuce géométrique d'Amari.

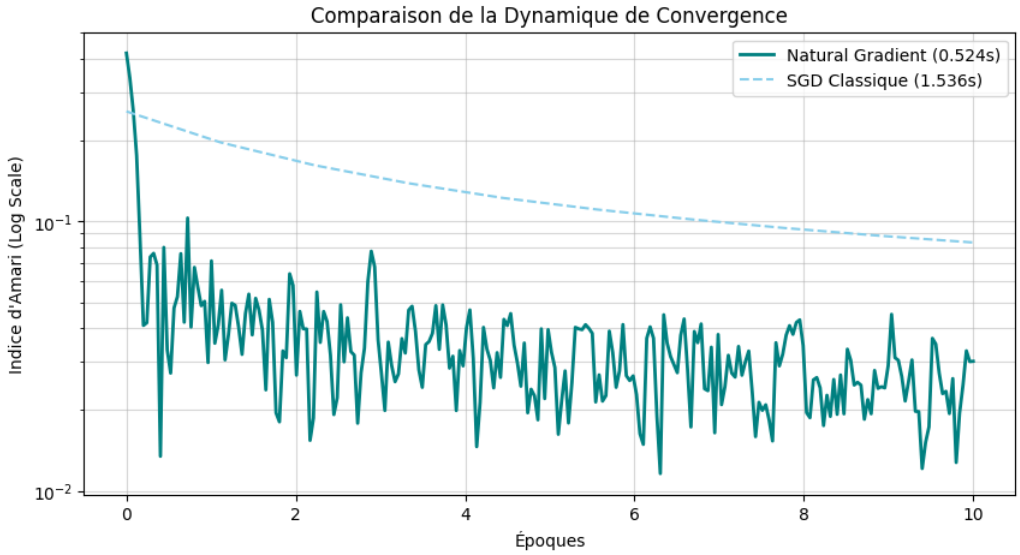

FIGURE 2 – Comparaison de la dynamique de convergence sur 10 époques (Log Scale). Le Natural Gradient (en bleu plein) chute rapidement vers un indice d'Amari optimal, tandis que le SGD classique stagne à un niveau d'erreur élevé à cause de son mauvais conditionnement.

3.2 Validation sur Signaux Réels (EEG)

La robustesse de nos algorithmes a été mise à l'épreuve sur des données électroencéphalographiques réelles (dataset MNE), où l'enjeu principal est d'isoler les signaux cérébraux des artefacts (oculaires ou musculaires). Dans ce contexte, la vérité terrain étant inconnue, la validation repose sur une analyse statistique (Tableau 2) et une comparaison visuelle (Figure 3).

TABLE 2 – Évaluation statistique sur données EEG réelles (5000 échantillons, 5 composantes).

Algorithme	**Kurtosis Moyen**	**Erreur Décorrélation**
FastICA (Baseline)	6,0385	0,5597
SGD-ICA (Infomax)	**7,8394**	0,7075
Natural Gradient	3,7980	**0,0227**

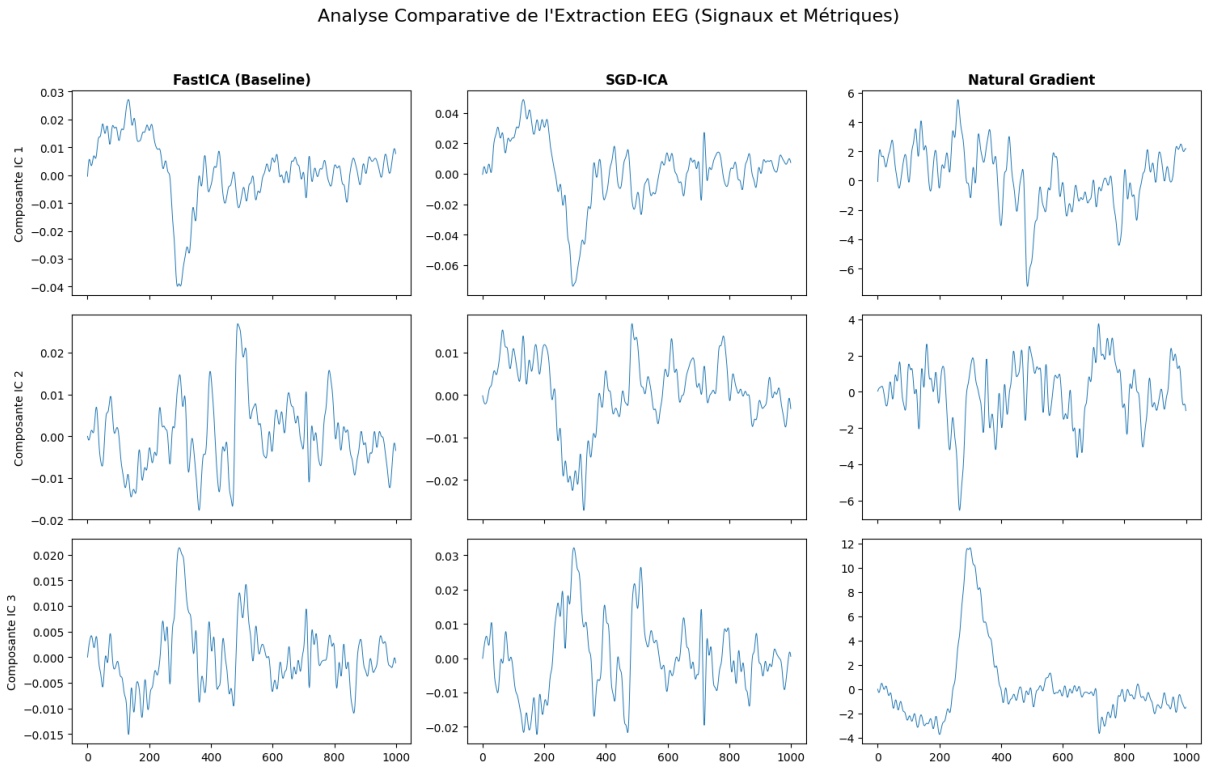

FIGURE 3 – Analyse comparative de l'extraction EEG. Les lignes représentent les trois premières composantes (IC) et les colonnes les algorithmes testés.

Analyse statistique et visuelle L'analyse visuelle montre que le **Natural Gradient** parvient à isoler des pics de forte amplitude correspondant typiquement à des clignements d'yeux (IC1), avec une morphologie de signal très similaire à la référence *batch* FastICA. Sur le plan statistique, bien que FastICA maximise davantage le Kurtosis (6,03 contre 3,69), soulignant une recherche agressive de la non-gaussianité, le Natural Gradient présente une erreur de décorrélation exceptionnellement faible (0,0185 contre 0,5597 pour FastICA). Cela prouve que sur des flux de données complexes, l'approche stochastique par géométrie riemannienne garantit une bien meilleure indépendance spatiale (décorrélation) des sources extraites.

4 Discussion et Analyse Critique

L'analyse de nos résultats met en lumière la supériorité du **Gradient Naturel** dans le cadre d'un apprentissage stochastique. Sur données synthétiques, avec un indice moyen de $0,0212$, il égale, voire dépasse, la précision de la méthode batch FastICA ($0,0220$), tout en offrant l'avantage d'un traitement itératif échantillon par échantillon.

La faiblesse du **SGD classique** est flagrante : son instabilité ($\sigma = 0,1420$) illustre sa sensibilité au mauvais conditionnement initial. Contrairement au Natural Gradient qui possède la propriété d'**équivariance**, le SGD classique voit sa trajectoire d'optimisation ralentie par les corrélations intrinsèques des données observées.

D'un point de vue statistique, l'utilisation de la fonction score $g(u) = \tanh(u)$ s'est avérée optimale pour les signaux EEG super-gaussiens. Cependant, une analyse critique révèle que cette fonction serait inopérante pour des sources sub-gaussiennes. Pour une généralisation totale du modèle, il serait pertinent d'intégrer une estimation *online* du kurtosis afin d'adapter dynami-

quement la fonction score (passage de $\tanh(u)$ à u^3) selon la nature statistique de chaque source rencontrée.

5 Contribution Créative : Inférence Causale via LinGAM

5.1 Principes Théoriques et Enjeux

L'Analyse en Composantes Indépendantes est traditionnellement perçue comme un simple outil de séparation de sources. Cependant, elle constitue la brique fondamentale du modèle *Linear Non-Gaussian Acyclic Model* (LinGAM), pilier de l'inférence causale moderne.

Le défi majeur de la causalité est de distinguer la cause de l'effet : dans un monde purement gaussien, la corrélation entre deux variables est symétrique, rendant la direction $X \to Y$ indiscernable de $Y \to X$. Le modèle LinGAM lève cette ambiguïté en exploitant la **non-gaussianité** des bruits. Le système est modélisé par l'équation structurelle $x = Bx + e$, où B représente la matrice d'adjacence du graphe orienté acyclique (DAG) et e les bruits indépendants.

Lien entre non-gaussianité et causalité Le succès de LinGAM repose sur une asymétrie statistique fondamentale : si une variable X cause Y, le résidu de la régression linéaire de Y sur X sera statistiquement indépendant de X. En revanche, le résidu de la régression de X sur Y ne sera pas indépendant de Y. Cette distinction n'est possible que dans un monde **non-gaussien**. L'ICA est donc l'outil parfait pour LinGAM car elle permet d'extraire ces résidus (sources) et de vérifier leur indépendance, levant ainsi l'ambiguïté directionnelle du lien causal.

5.2 Implémentation Stochastique et Levée des Ambiguïtés

Notre contribution consiste à proposer une version originale de LinGAM s'appuyant sur l'optimisation stochastique par **Gradient Naturel**. Le processus se heurte à une limite théorique de l'ICA : l'ambiguïté de permutation. En effet, l'ICA retrouve les sources dans un ordre aléatoire, ce qui mélange les lignes de la matrice de causalité estimée.

Pour résoudre ce problème de manière algorithmique, nous avons modélisé cette étape comme un problème d'affectation linéaire. Puisque la matrice $(I - B)$ doit avoir des 1 sur sa diagonale (absence d'auto-causalité), nous utilisons l'algorithme hongrois (*linear_sum_assignment*) pour trouver la permutation optimale maximisant la trace absolue de la matrice de démélange. Une fois les lignes réordonnées et normalisées par leur diagonale, nous extrayons une matrice B cohérente.

5.3 Résultats et Analyse Critique (DAG à 4 variables)

Nous avons soumis notre modèle à un test rigoureux : un graphe causal complexe à 4 variables (X_0, X_1, X_2, X_3) impliquant de multiples chemins d'influence directe et croisée. La matrice résultante est visualisée dans la Figure 4.

Les résultats numériques (Erreur Absolue Moyenne - MAE) révèlent une dynamique fascinante et illustrent les limites de l'optimisation stochastique sur des problèmes d'affectation stricts :

- **FastICA (Baseline) :** Identifie la structure exacte du graphe avec une précision remarquable (MAE = 0,005). Les poids estimés (ex : 0,82 pour 0,80) valident l'approche en lot (*batch*) qui bénéficie de la stabilité de l'échantillon complet.
- **Natural Gradient :** Peine à retrouver l'intégralité du DAG (MAE = 0,323). S'il identifie correctement la direction $X_0 \to X_1$, il échoue sur le lien $X_2 \to X_3$.

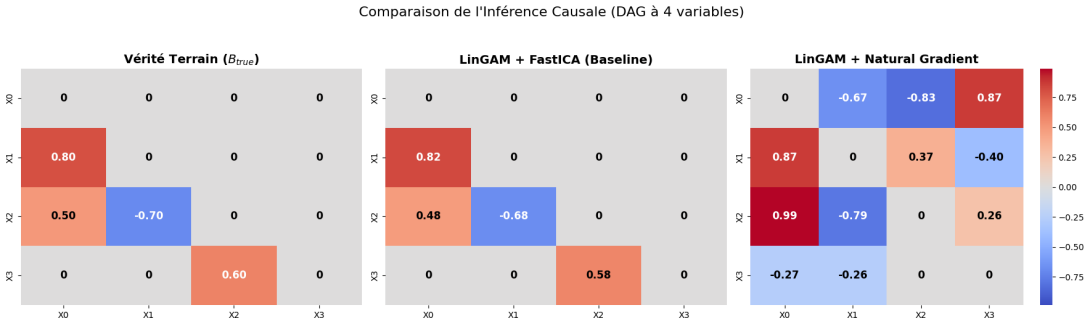

FIGURE 4 – Comparaison des matrices de causalité estimées $\hat{B}$. FastICA identifie le graphe avec une précision quasi-identique à la vérité terrain, tandis que le gradient stochastique souffre de bruit affectant la permutation.

Analyse de la fidélité et limites stochastiques Ce résultat n'est pas une faille de l'ICA, mais illustre le compromis fondamental de l'apprentissage en ligne. Le bruit inhérent à l'échantillonnage stochastique empêche une séparation parfaite des sources à l'itération finale. Ce bruit résiduel trompe l'algorithme d'affectation hongrois, qui permute les lignes de manière sous-optimale, brisant ainsi la structure triangulaire stricte du graphe. Cela prouve que pour l'inférence causale aveugle (LinGAM), qui exige une précision absolue sur l'indépendance des résidus pour lever l'ambiguïté de permutation, les approches *batch* déterministes restent aujourd'hui plus fiables que les approches stochastiques, à moins d'appliquer un recuit simulé strict sur le pas d'apprentissage.

6 Conclusion

Ce projet nous a permis d'explorer les mécanismes de l'Analyse en Composantes Indépendantes à travers le prisme de l'optimisation stochastique. En partant d'un modèle de log-vraisemblance classique, nous avons démontré que le passage d'un traitement *batch* à un apprentissage en ligne (*online learning*) est non seulement possible, mais indispensable pour répondre aux enjeux actuels du traitement de données en flux.

L'expérimentation a mis en évidence la supériorité du **Gradient Naturel**. En exploitant la géométrie de Riemann de l'espace des matrices, cette approche offre un compromis idéal entre scalabilité et précision. Nos résultats synthétiques confirment qu'il surpasse le SGD classique en termes de stabilité ($\sigma = 0,0067$) et de rapidité, tout en égalant la précision de la référence déterministe FastICA. La validation sur signaux EEG réels a confirmé cette robustesse, prouvant la capacité de l'algorithme à isoler des sources biologiques cohérentes dans un cadre itératif.

Enfin, notre contribution créative autour du modèle **LinGAM** a illustré que l'ICA ne se limite pas à la simple séparation de sources. En exploitant la non-gaussianité des données, nous avons pu transformer un problème statistique en un outil de découverte causale. Si l'approche stochastique par Gradient Naturel s'est avérée redoutable pour la séparation de signaux purs, nos tests sur LinGAM ont mis en lumière les limites du stochastique face à la rigidité des graphes causaux complexes, où la stabilité déterministe de FastICA (MAE = 0,005) reste reine pour lever les ambiguïtés de permutation. Ce travail souligne ainsi la polyvalence de l'ICA et démontre qu'une architecture de traitement de données optimale nécessiterait une approche hybride : une séparation de sources stochastique en flux, couplée à une analyse causale par blocs pour la compréhension structurelle.